

Title	사용자 요구 변화 추적을 위한 대화형 쇼핑 추천 제안
Summary (in 150 words)	기존 추천 시스템은 고정된 과거 데이터에 의존해 실제 쇼핑 과정에서 변화하는 요구와 거절 이유, 현재 정보 및 대화 맥락을 반영하기 어렵다. 본 연구는 대화 상태와 피드백을 검색·순위화에 지속 반영하는 쇼핑 에이전트 파이프라인을 제안하고, 상태 갱신부터 재추천까지의 수행 과정을 분석한다.
Advisor	노태형, 여해인, 한경식
Period	2026-06-23~2026-08-26

Name	Department	Student ID	Hanyang email	Phone
김진욱	데이터사이언스전공	2023036299	jwkim628@hanyang.ac.kr	010-4101-9515

College of Data Science
Hanyang University

1. Abstract

기존 추천 시스템은 최종 구매 결과를 중심으로 사용자의 선호를 추정하기 때문에, 지속적인 선호와 특정 구매 상황에서 발생한 제약을 구분하지 못하는 한계가 있다. 본 연구는 구매 결과뿐 아니라 제약 조건, 후보 탐색, 거절, 우선순위, 타협 과정을 대화 상태(Dialogue State)에 누적하는 대화형 쇼핑 에이전트 파이프라인을 제안한다.

파이프라인은 단일 에이전트 기반의 명시적 LangGraph 워크플로우로 구성된다. SPN Understanding은 사용자 발화에서 상태 갱신 후보를 추출하고, 결정론적 RA-Rec State Manager는 이를 병합해 근거 출처와 상태 변화를 관리한다. 이어 SPN Policy는 누적된 Dialogue State를 바탕으로 추가 질문 또는 추천 중 하나의 경로를 선택하며, 추천 경로에서는 Query Generator, 상품 필터링, 의미 기반 리뷰 검색, Recommendation Engine이 순서대로 추천 결과를 생성한다. 실제 상품·리뷰 검색에는 Amazon Reviews 2023 Electronics에서 구축한 태블릿 117개와 중복 제거된 실제 리뷰 7,552개를 사용했다.

사전에 동결한 20개 다중 턴 시나리오(총 81턴)에 대해

Full vs. No-Memory, Review vs. No-Review에 대한 비교를 진행하였다.

Metric	Full	No-Memory	Difference	95% bootstrap CI
Final State micro-F1	0.758	0.500	+0.258	[+0.172, +0.334]
State Diff micro-F1	0.562	0.700	-0.138	[-0.222, -0.056]
Policy Accuracy	0.802	0.741	+0.062	[-0.111, +0.222]
Recommendation Reach	0.808	0.744	+0.064	[-0.103, +0.231]
Hard-filter completion	0.630	0.444	+0.185	[+0.000, +0.363]

[Full vs. No-Memory]

Full 조건은 No-Memory보다 네 지표에서 우세하였으나, 턴별 State Diff micro-F1은 Full 조건이 더 낮았다. 지속 메모리가 누적 상태 보존에는 기여하지만, 이전 상태의 정보를 현재 턴에서 새롭게 발생한 변화로 중복 추출하는 경향을 보여준다.

[No-Review] 동일한 조건에서 리뷰 점수와 신뢰도를 상품 선정 기준에서 제거.

Ranking behavior	Result
Top-1 changed	55.6%
Top-3 order changed	87.3%
Mean Top-3 Jaccard	0.522

리뷰 기반 점수를 제거한 경우 **Top-1** 추천의 **55.6%**, **Top-3** 상품 순서의 **87.3%**가 변화

두 실험의 결과는 쇼핑 대화에서 지속 상태가 사용자의 조건과 피드백을 추천 단계까지 전달하는 데 유용함을 보여주는 동시에, 상태 갱신 정밀도와 구조화 출력 안정성이 함께 개선되어야 함을 시사한다.

2. Introduction

온라인 쇼핑에서 사용자의 요구는 구매를 시작하기 전에 완전히 정해져 있기보다, 상품을 탐색하고 비교하는 과정에서 점차 구체화되는 경우가 많다. 새로운 상품이나 리뷰를 접하면서 조건을 추가하거나 수정하기도 하고, 특정 후보를 제외하거나 가격·성능·배송·사용 목적 사이의 우선순위를 다시 정하기도 한다. 따라서 대화형 쇼핑 에이전트가 사용자의 의사결정을 충분히 지원하려면 현재 발화에서 드러난 요구를 이해하는 데 그치지 않고, 이전 대화에서 확인된 조건과 피드백이 이후 상호작용에서 어떻게 유지되고 변화하는지도 함께 다룰 필요가 있다.

본 연구에서는 이러한 문제를 살펴보기 위해, 처음 구매하는 제품군, 취향이 중요한 제품, 특정 상황을 위한 제품, 선물 및 고관여 제품 등 여러 구매 상황에서 상용 쇼핑 에이전트의 사용 사례를 사전 탐색하였다. 에이전트는 상품을 유형별로 정리하고 실제 가격과 특징을 함께 제시했으며, 사용자가 추가한 조건에 따라 추천을 일부 조정할 수 있었다. 반면 요구가 모호한 상황에서도 추가 질문을 통해 범위를 좁히기보다는 여러 후보를 계속 제시하는 경우가 있었고, 대화가 이어져도 추천 후보가 충분히 압축되지 않았다. 또한 상품의 장점에 비해 단점이나 추가 비용, 구매 요소 사이의 우선순위, 배송·설치·유지관리와 같은 구매 이후의 조건은 상대적으로 적게 다루어졌다. 그 결과 상품 탐색에 필요한 노력은 줄어들었지만, 여러 후보를 비교하고 자신에게 적합한 선택을 판단·검증하는 부담은 여전히 사용자에게 남아 있었다. 이러한 관찰은 대화 중 새롭게 드러나는 요구와 피드백을 일회성 검색 조건으로만 활용하는 것이 아니라, 이후의 추천 과정에서 지속적으로 유지하고 반영할 필요가 있다는 문제의식으로 이어졌다.

추천 시스템 연구에서는 사용자 프로필과 상호작용 이력으로부터 **preference**와 **intent**를 추론하고 이를 추천에 활용하는 다양한 접근이 제안되어 왔다^{1,2,3}. 최근에는 LLM을 이용해 일반적인 선호와 단기적인 의도를 함께 추론하거나, 여러 의도 사이의 시간적·인과적 관계를 모델링하려는 연구도 이루어지고 있다. 이러한 연구는 사용자 의도가 하나의 고정된 레이블로만 설명되지 않으며, 시간과 맥락에 따라 달라질 수 있음을 보여준다. 다만 기존 연구가 주로 다루는 변화는 사용자 행동 이력이나 세션, 의도 그래프 수준에서 나타나는 변화에 가깝다. 현재 사용자와의 대화에서 새로운 조건이 추가되거나 기존 조건이 수정되고, 특정 후보를 거절하거나 우선순위를 변경하는 과정을 발화 단위의 사용자별 상태 변화로 관리하는 문제는 상대적으로 덜 다루어져 왔다.

이러한 구분은 실제 구매 행동을 해석할 때 더욱 중요하다. 최종 구매 행동만 놓고 보면 지속적인 선호와 특정 상황에서 발생한 제약을 구분하기 어렵기 때문이다. 예를 들어 빠른 배송이 필요해 평소보다 비싼 상품을 선택했다고 해서 사용자가 고가 제품을 선호한다고 보기는 어렵다. 원하는 색상의 재고가 없어 다른 색상을 구매한 경우 역시 마찬가지다. 최종 선택만으로는 이러한 차이를 알기 어렵기 때문에, 대화 과정에서 어떤 조건이 확인되었고 무엇이 수정되거나 제외되었는지를 함께 유지할 필요가 있다.

이에 본 연구는 새로운 **intent representation** 자체를 제안하기보다, 대화 과정에서 변화하는 사용자 요구와 피드백을 지속적인 상태로 관리하고, 이러한 변화가 이후의 추천 과정까지 반영될 수 있는 구조를 구성하는 데 초점을 둔다.

3. Literature Review

3.1 LLM-based Intent Modeling for Recommendation

최근 추천 시스템에서는 LLM의 추론 능력을 활용해 사용자 행동으로부터 **preference**와 **intent**를 추론하고, 이를 추천 과정에 반영하려는 연구가 이루어지고 있다. CORONA는 사용자 프로필에서 비교적 장기적인 **preference**를, 최근 **interaction history**에서 단기적인 **intent**를 추론한 뒤 이를 단계적인 **candidate filtering**과 GNN 기반 **ranking**에 활용한다^[3]. RIGRec은 **session behavior**에서 생성된 **intention** 사이의 **temporal·causal·conceptual relation**을 그래프로 구성하고, 이러한 관계 정보를 **recommendation**에 반영한다^[4].

두 연구는 LLM 기반 **intent reasoning**이 기존 **recommendation pipeline**의 **retrieval**과 **ranking**을 보완할 수 있음을 보여준다. 다만 주된 관심은 사용자 행동 이력이나 세션으로부터 **intent**를 추론하거나 **intention** 간 관계를 모델링하는 데 있으며, 대화 중 조건이 추가·수정·거절되는 과정을 사용자별 상태로 지속적으로 추적하는 문제와는 초점이 다르다.

3.2 A Shopping Agent for Addressing Subjective Product Needs

A Shopping Agent for Addressing Subjective Product Needs는 모호하고 주관적인 사용자 요구를 처리하기 위해 질문, 상품 탐색, 리뷰 탐색, 설명 생성을 하나의 **shopping agent workflow**로 구성한다^[5]. 사용자 요구를 **Subjective Property, Event, Activity, Goal Purpose, Goal Audience**의 다섯 가지 **facet**으로 구분하고, 필요한 정보가 부족한 경우 추가 질문을 통해 요구를 구체화한 뒤 상품과 리뷰를 탐색한다.

본 연구는 이러한 접근을 사용자의 요구를 이해하고, 필요한 경우 질문하며, 적절한 시점에 상품과 리뷰를 탐색하는 **agent workflow**의 기반으로 활용한다. 다만 해당 방식은 사전에 정의된 **agent workflow**를 중심으로 동작하며, 보다 유연한 **action selection**은 향후 과제로 제시된다.

3.3 Dialogue State and Review-grounded Recommendation

Dialogue State Tracking은 대화가 진행되는 동안 사용자의 목표와 제약 등 **task-relevant state**를 지속적으로 추적하는 문제로 다루어져 왔다^[6]. RA-Rec은 대화를 통해 축적된 사용자 **preference**를 **Dialogue State**로 유지하고, 상품에 대한 근거는 **review**와 **metadata**에서 별도로 검색하는 구조를 제안한다^[7]. **Dialogue State**는 **semi-structured JSON** 형태로 표현되며, **hard/soft constraint**와 자연어 **preference**를 저장한 뒤 **action selection**과 **retrieval**의 입력으로 사용된다. 또한 현재 발화만을 **query**로 사용하는 대신 누적된 **Dialogue State**를 이용해 **review**와 **metadata**를 검색하고, 이를 **recommendation**과 **explanation**의 근거로 활용한다.

이러한 구조는 본 연구에서 사용자 상태와 상품 근거를 분리해 다루는 방식의 직접적인 기반이 된다. 본 연구는 여기서 더 나아가, 대화 과정에서 어떤 조건이 유지되고 무엇이 새롭게 추가·수정·거절되는지를 상태 변화로 구분해 관리하며, 이러한 변화가 이후의 **retrieval**과 **ranking**까지 어떻게 이어지는지를 다룬다.

4. Methodology

4.1 Overview

본 연구는 다중 턴 쇼핑 과정에서 사용자의 요구 변화와 상품에 대한 피드백을 지속적으로 추적하고, 이를 상품 검색과 순위화에 반영하는 상태 기반 쇼핑 에이전트 파이프라인을 구성하였다.

전체 시스템은 **PLAN-MEMORY-DECIDE-ACT-RESPOND**의 단계로 구성되며, 각 단계는 명시적인 LangGraph workflow를 통해 연결된다.

시스템은 LLM의 역할과 결정론적 로직의 역할을 분리하였다. LLM은 현재 사용자 발화와 제한된 이전 대화 상태를 바탕으로 사용자 의도와 상태 갱신 후보를 구조화하는 **Understanding** 단계와 최종 자연어 응답 생성에 사용된다.

반면 **Dialogue State** 병합, 재질문 여부 결정, 검색 질의 생성, 상품 **filtering**, 리뷰 검색, 상품 **ranking**은 결정론적인 코드로 수행한다. 이를 통해 LLM 출력의 비결정성이 상태 관리와 추천 로직 전체로 전파되는 것을 제한하고, 각 모듈의 동작과 오류를 독립적으로 추적할 수 있도록 하였다.

전체 처리 과정은 다음과 같다.

User Utterance → PLAN (Understanding) → MEMORY (Dialogue State) → DECIDE (Policy)
→ ACT (Query/Browse/Rank) → RESPOND → User Feedback

Policy 결과에 따라 시스템은 추가 정보를 묻는 **Clarify Lane**과 상품 검색 및 추천을 수행하는 **Recommend Lane** 중 하나로 분기한다.

4.2 PLAN: Structured User Utterance Understanding

PLAN 단계에서는 LLM 기반 **Understanding** 모듈이 현재 사용자 발화를 구조화된 상태 갱신 후보(**State Update Candidate**)로 변환한다. 이 단계는 **Dialogue State**를 직접 수정하지 않으며, 현재 발화에서 새롭게 관찰된 정보만 다음 **State Manager**에 전달한다.

Understanding 모듈은 사용자 발화를 **search, refine, reject, inspect, compare, purchase** 등의 intent로 구분하고, 사용자 요구를 다음과 같은 SPN 기반 **facet**으로 구조화한다.

- **Subjective Property**: 성능, 휴대성, 화면 품질 등 사용자가 중요하게 생각하는 질적 특성

- **Event:** 기존 기기 고장, 첫 구매, 교체, 선물 등 구매를 촉발한 사건
- **Activity:** 필기, 게임, 영상 시청, 독서 등 예상 사용 활동
- **Goal/Purpose:** 장기 사용, 학업·업무, 엔터테인먼트 등 구매 목적
- **Goal/Audience:** 본인, 자녀, 가족 등 제품 사용자

동시에, 요구 조건은 **hard** 또는 **soft constraint** 후보로 추출된다. 각 후보에는 자연어 표현뿐 아니라 미리 정의된 **canonical_id**, 근거가 등장한 발화, **confidence**와 **evidence origin**이 포함된다. **Evidence origin**은 사용자가 직접 언급한 **explicit**, 발화에서 직접적으로 도출할 수 있는 **implicit**, 추가 추론이 필요한 **inferred**로 구분한다.

특히 **ranking**이나 상태 비교에 사용되는 의미 표현에는 **closed vocabulary**를 적용하였다. LLM이 자유로운 자연어로 새로운 내부 상태 이름을 생성하는 대신 정해진 **canonical ID** 중 하나를 선택하도록 하여, 이후의 상태 비교와 상품 속성 **mapping**을 결정론적으로 수행할 수 있도록 하였다.

이전 **Dialogue State**는 현재 발화의 의미를 해석하거나 “첫 번째 상품”, “그 제품은 제외해 줘”와 같은 문맥 의존적 행동을 해결하기 위한 보조 문맥으로 제공된다. 이전 추천 결과 역시 상위 상품의 **rank**와 상품명 수준으로 제한하여 제공한다.

4.3 MEMORY: Persistent Dialogue State Management

MEMORY 단계는 **PLAN**에서 생성한 갱신 후보를 기존 **Dialogue State**와 병합한다. **State Manager**는 사용자 발화를 다시 LLM으로 해석하지 않고, 검증된 **Understanding** 결과만을 입력으로 받는 결정론적 모듈이다.

Dialogue State는 단순한 선호 슬롯뿐 아니라 다음 정보를 포함한다.

- product category
- hard constraints
- soft constraints
- five subjective-need facets
- trade-offs
- recommended items
- shortlisted items
- inspected items
- rejected items와 rejection reason
- current item
- carted/purchased items
- unresolved preferences
- turn별 preference history

각 **Preference Value**에는 **canonical ID**와 자연어 값뿐 아니라 **origin, confidence, status, evidence_turn_ids, updated_at_turn_id**를 기록한다. 상태의 **status**는 **confirmed, unconfirmed, superseded**로 구분한다.

Explicit 또는 **implicit**하게 확인된 요구는 **confirmed** 상태로 관리하는 반면, **inferred** 정보는 **unconfirmed** 상태로 저장한다. 또한 기존의 **confirmed** 값을 이후의 단순 추론 결과가 덮어쓰지 못하도록 하여 확인된 사용자 요구가 불확실한 추론에 의해 손실되는 것을 방지한다.

사용자가 기존 추천 상품을 거절하거나 비교·상세조회·구매하면 해당 행동 역시 상태에 반영된다. 특히 **rejection**은 단순히 상품을 제거하는 데 그치지 않고, 거절 이유를 **situational constraint**와 **product attribute**로 구분해 기록한다. 이후 추천에서는 **rejected item**을 후보군에서 제외한다.

각 턴 이후에는 전체 **State**와 별도로 이번 턴에서 변경된 경로만을 나타내는 **State Diff**를 생성한다. 이를 통해 장기적으로 유지되는 사용자 상태와 현재 발화로 인해 새롭게 발생한 변화를 구분한다.

4.4 DECIDE: Clarification and Recommendation Policy

업데이트된 **Dialogue State**를 기반으로 다음 행동을 결정하기 위해 결정론적 **Policy**를 사용한다. **Policy**는 현재 발화 자체나 LLM의 자유형 reasoning을 직접 사용하지 않고 **Dialogue State**만을 입력으로 받는다.

시스템은 상태의 구체성을 나타내는 **vagueness score**를 계산한다. 태블릿 도메인이 확립되지 않았거나, 예산이 확인되지 않았거나, 주요 사용 목적 또는 **ranking** 기준이 부족하면 **vagueness score**가 증가한다. 현재 구현에서는 **threshold**를 45로 설정하였다.

상태 정보가 충분하지 않거나 지원하지 않는 상품군이 요청된 경우 시스템은 **Clarify Lane**을 선택하여 가장 우선순위가 높은 미확정 조건에 대해 추가 질문을 생성한다. 반대로 사용자 상태가 상품을 구분할 정도로 충분히 구체적이면 **Recommend Lane**으로 진행한다.

이 구조는 요구가 모호한 상태에서 즉시 많은 상품을 제시하기보다, 상품 선택에 중요한 정보를 우선적으로 확보한 뒤 추천을 수행하도록 설계되었다.

4.5 State-conditioned Query Generation and Catalog Filtering

Recommend Lane에서는 현재 **Dialogue State**를 검색 가능한 표현으로 변환한다. 이 단계에서는 **status=confirmed**인 정보만 검색과 **ranking**에 활용함으로써 아직 확인되지 않은 **inferred preference**가 상품 선택을 직접 지배하지 않도록 한다.

Hard constraint는 구조화된 **catalog filter**로 변환된다. 현재 태블릿 실험에서는 다음과 같은 조건을 지원한다.

- maximum price
- minimum storage
- minimum memory
- maximum weight
- minimum rating
- minimum display size
- operating system

Soft constraints와 **subjective needs**는 검색어와 **ranking signal**로 변환된다. 예를 들어 **note-taking** 요구는 **note taking**, **display**, **portability**와 관련된 속성에, **gaming** 요구는 **memory**와 **display** 관련 속성에 **mapping**된다.

조건을 만족하는 상품을 **catalog**에서 최대 300개까지 가져온 후 이전 대화에서 거절된 상품을 제거한다. 실험의 실제 상품 데이터는 **Amazon Reviews 2023**의 **Electronics** 데이터를 가공하여 구축한 태블릿 **catalog**를 사용한다^[6]. 동결된 실험 환경에는 117개 상품과 7,552개 리뷰가 포함된다.

4.6 Review Evidence Retrieval

상품 설명이나 정형 **metadata**만으로 표현하기 어려운 배터리 경험, 필기감, 성능, 내구성 등의 주관적 요구를 반영하기 위해 실제 사용자 리뷰를 별도의 **evidence source**로 검색한다 [9].

리뷰 검색은 두 단계로 수행한다.

첫째, **sentence-transformers/all-MiniLM-L6-v2 Bi-Encoder**를 이용하여 사용자 상태에서 생성된 **query**와 각 상품 리뷰 간 **embedding similarity**를 계산한다. 상품별 상위 5개 리뷰를 후보로 선택한다 [10].

둘째, 선택된 리뷰에 대해 **cross-encoder/ms-marco-MiniLM-L6-v2 Cross-Encoder**를 적용하여 **query-review relevance**를 다시 계산하고 상품별 상위 3개 리뷰를 남긴다. Bi-Encoder cosine score와 Cross-Encoder score는 각각 0.35와 0.65의 가중치로 결합한다.

Cross-Encoder 또는 **semantic index**를 사용할 수 없는 경우에는 명시적인 **token-based retrieval**로 **fallback**하며, **fallback** 여부와 원인을 **trace**에 기록한다.

검색된 리뷰에는 **relevance**뿐 아니라 사용자의 어떤 **preference**와 연결되는지와 **evidence reliability**를 계산한다. 리뷰 점수는 다음과 같이 정의한다.

$$ReviewScore = 0.65S_{similarity} + 0.25S_{coverage} + 0.10S_{reliability}$$

4.7 State-aware Product Ranking

후보 상품은 Dialogue State와 review evidence를 함께 이용하여 결정론적으로 **ranking**한다. 각 상품의 최종 점수는 다섯 가지 요소로 구성된다.

- Hard Constraint Match
- Metadata Match
- Subjective Need Match
- Review Evidence Score
- Evidence Reliability

$$Score(p) = 0.30H_p + 0.30M_p + 0.20S_p + 0.15R_p + 0.05E_p$$

Hard Constraint Match는 가격, 저장 용량, 메모리, 무게, 평점, 화면 크기, 운영체제 등의 명시적 제약 충족도를 평가한다. Metadata Match는 **soft constraint**와 상품 정형 속성의 일치 정도를 나타내며, Subjective Need Match는 **activity**와 **goal** 등의 상태가 상품 속성과 얼마나 부합하는지를 나타낸다.

Review Evidence Score는 해당 상품에서 검색된 상위 **review evidence**의 평균 점수를 사용하며, Evidence Reliability는 사용된 리뷰 자체의 신뢰도와 상품별 리뷰 수를 함께 고려한다.

각 상품에는 최종 점수뿐 아니라 어떤 **preference ID**와 일치했는지, 어떤 **review ID**가 **evidence**로 사용되었는지를 함께 기록한다. 이를 통해 최종 추천 상품과 추천에 사용된 상태·리뷰 근거를 연결할 수 있도록 하였다.

4.8 RESPOND: Evidence-grounded Response Generation

마지막 **RESPOND** 단계에서는 LLM이 사용자가 읽을 자연어 응답을 생성한다. 그러나 LLM은 상품을 새롭게 검색하거나 순위를 변경하지 않는다. 입력으로는 이미 결정된 **Top-ranked products**, **deterministic score**, 상품 **metadata**와 실제 **ranking**에 사용된 **review excerpts**만 제공된다.

Clarify Lane에서는 Policy가 지정한 단일 question target에 대한 간결한 추가 질문을 생성하며, Recommend Lane에서는 상위 상품과 상태의 일치 이유를 설명한다.

Response Composer에는 제공된 상품 필드와 review evidence만 사용하고, 존재하지 않는 배송·재고·색상 등의 정보를 생성하지 않도록 제약을 부여하였다. 최종 화면에 표시되는 review evidence 역시 실제 상품 ranking에 사용된 evidence_review_ids와 연결된다.

따라서 자연어 설명의 유연성은 LLM에 맡기되, 무엇을 추천할지와 어떤 근거가 사용되었는지는 결정론적인 recommendation pipeline에 의해 고정된다.

4.9 Multi-turn Feedback Loop

사용자의 다음 발화는 이전 추천 결과와 누적 Dialogue State를 기반으로 다시 PLAN 단계에 입력된다. 사용자는 새로운 제약을 추가하거나, 기존 조건을 수정하거나, 추천 상품을 상세 조회·비교·거절·구매할 수 있다.

이러한 행동은 다시 Dialogue State에 누적되며 이후 query와 ranking을 변화시킨다. 따라서 시스템은 각 턴을 독립적인 상품 검색으로 처리하는 대신,

사용자 발화 → 상태 변화 → 후보 변화 → 추천 → 사용자 피드백 → 새로운 상태

로 이어지는 반복적인 의사결정 과정으로 쇼핑 대화를 모델링한다.

본 연구에서 핵심적으로 관찰하는 대상 역시 최종 상품 하나의 정답 여부뿐 아니라, 대화 과정에서 사용자 요구가 올바르게 유지·수정되고 해당 상태 변화가 실제 검색과 추천 결과까지 전달되는지이다.

5. Results

본 연구에서는 다중 턴 쇼핑 대화에서 Dialogue State를 지속적으로 유지하는 것이 사용자 요구의 보존과 후속 추천 과정에 어떠한 영향을 미치는지 평가하였다. Amazon Reviews 2023에서 구축한 태블릿 117개와 리뷰 7,552개를 이용하였으며, 태블릿 구매를 가정한 20개의 독립적인 multi-turn scenario, 총 81개 turn을 대상으로 실험하였다.

5.1 Effect of Persistent Dialogue State

Dialogue State의 지속적 관리 효과를 확인하기 위해 이전 턴까지 누적된 Dialogue State를 유지하는 Full 조건과 현재 턴에서 확인된 정보만을 사용하는 No-Memory 조건을 비교하였다.

Metric	Full	No-Memory	Difference	95% bootstrap CI
Final State micro-F1	0.758	0.500	+0.258	[+0.172, +0.334]
State Diff micro-F1	0.562	0.700	-0.138	[-0.222, -0.056]
Policy Accuracy	0.802	0.741	+0.062	[-0.111, +0.222]

Recommendation Reach	0.808	0.744	+0.064	[-0.103, +0.231]
Hard-filter completion	0.630	0.444	+0.185	[+0.000, +0.363]

Full 조건의 **Final State** micro-F1은 0.758로 No-Memory의 0.500보다 **0.258** 높게 나타났다.

이는 이전 대화에서 확인된 사용자 요구를 지속적으로 보존하는 것이 대화 종료 시점의 누적 사용자 상태를 정확하게 구성하는 데 효과적임을 보여준다.

반면 턴별로 새롭게 변경된 상태만을 평가하는 **State Diff** micro-F1은 Full에서 0.562, No-Memory에서 0.700으로 나타났다. 즉, **Dialogue State**를 지속적으로 유지하면 장기적인 사용자 요구 보존에는 유리하지만, 과거에 이미 확인된 정보를 현재 턴에서 새롭게 추가된 정보와 구분하는 것은 오히려 어려워지는 양상이 관찰되었다.

Policy Accuracy와 Recommendation Reach 역시 Full 조건이 각각 +0.062, +0.064 높았다. Hard-filter Completion은 Full 0.630, No-Memory 0.444로 차이가 +0.185였다.

따라서 본 실험에서 가장 명확한 차이는 누적 **Final State**의 보존 성능과 턴별 **State Diff** 성능 사이의 상반된 변화에서 나타났다.

5.2 Gold-State Diagnostic Analysis

Full 조건에서 발생한 성능 손실이 pipeline의 어느 단계에서 비롯되는지 확인하기 위해, 시스템이 추론한 **Dialogue State**를 사전에 정의한 **Gold Dialogue State**로 대체한 diagnostic analysis를 수행하였다.

Metric	Actual Full	Gold-State	Recovery
Policy Accuracy	0.802	1.000	+0.198
Recommendation Reach	0.808	1.000	+0.192
Hard-filter Completion	0.630	1.000	+0.370

Gold-State를 입력한 경우 Policy Accuracy, Recommendation Reach, Hard-filter Completion이 모두 **1.000**으로 회복되었다.

이 결과는 현재 시스템의 downstream Policy, Query Generation 및 hard filtering 자체보다, 이들 모듈에 전달되는 **Dialogue State**의 추론과 구성 과정이 주요 성능 손실 지정일 가능성을 보여준다.

5.3 Contribution of Review Evidence to Ranking

사용자 리뷰 정보가 실제 상품 순위 결정에 어느 정도 영향을 미치는지 확인하기 위해, 동일한 사용자 상태와 상품 후보를 유지한 채 review-based score의 기여를 제거하는 ablation analysis를 수행하였다.

Ranking behavior	Result
Top-1 changed	55.6%
Top-3 order changed	87.3%

Mean Top-3 Jaccard	0.522
--------------------	-------

Review 정보를 제거한 경우 **Top-1** 추천 상품의 **55.6%**가 변경되었으며, **Top-3** 상품의 순서까지 고려하면 **87.3%**의 **ranking**이 변화하였다. 두 조건에서 Top-3 상품 집합의 평균 Jaccard similarity는 0.522였다.

이는 review evidence가 단순히 최종 응답의 설명을 보조하는 정보로 사용되는 것이 아니라, 사용자 요구와 상품 사이의 적합도를 계산하여 실제 상품 ranking을 변화시키는 신호로 작동하고 있음을 보여준다.

본 실험에서는 추천 상품에 대한 human relevance label이나 사용자 만족도 평가를 수행하지 않았다. 따라서 review 정보가 ranking에 영향을 준다는 것은 확인할 수 있으나, 이러한 변화가 실제 recommendation accuracy 또는 사용자 관점의 추천 품질을 향상시켰다고 해석하는 데는 무리가 있다.

6. Limitations & Future Work

본 연구는 다중 턴 쇼핑 대화에서 **Dialogue State**를 지속적으로 유지하는 것이 누적 사용자 요구를 보존하는데 효과적임을 확인하였으나, 몇 가지 한계가 존재한다.

첫째, 이전 **Dialogue State**의 유지와 현재 턴의 실제 상태 변화를 정확하게 구분하는 데 한계가 있다. Full 조건은 No-Memory 조건에 비해 Final State micro-F1이 0.258 높았지만, State Diff micro-F1은 오히려 0.138 낮게 나타났다. 이는 이전 턴에서 이미 확인된 정보가 현재 턴에서 새롭게 추가된 정보처럼 다시 인식되는 경우가 존재함을 의미한다. 향후에는 현재 발화에 직접 근거한 상태 변화만을 추출하고, 기존 상태의 단순 carryover와 실제 ADD·UPDATE·DELETE를 명시적으로 구분하는 방식 등 보다 정교한 State Tracking 및 State Update 방법을 검토할 필요가 있다.

둘째, 현재 평가 환경만으로 실제 추천 품질을 직접 판단하기 어렵다. 본 연구의 20개 multi-turn scenario는 연구자가 구매 상황과 요구 변화를 통제하기 위해 직접 구성하였으며, 각 scenario에서 어떤 상품이 최적의 추천인지에 대한 gold product 또는 human relevance label은 정의하지 않았다. 따라서 Dialogue State와 hard constraint가 올바르게 유지되는지는 평가할 수 있지만, 최종적으로 제시된 상품이 실제 사용자에게 가장 적절한 선택이었는지는 검증하지 못한다. 또한 review evidence를 제거했을 때 Top-1 추천의 55.6%, Top-3 순서의 87.3%가 변화하였으나, 이는 review가 ranking에 영향을 준다는 것을 보여줄 뿐 해당 변화가 더 나은 추천으로 이어졌다는 것을 의미하지 않는다. 향후에는 실제 사용자 interaction과 다수 annotator의 relevance judgment를 수집하고, NDCG, pairwise preference, recommendation acceptance, 사용자 만족도 등의 지표를 통해 추천 품질을 직접 평가할 필요가 있다.

셋째, 평가가 제한된 상품군과 통제된 interaction에 집중되어 있다는 점에서 일반화 가능성에 한계가 있다. 현재 실험은 Amazon Reviews 2023에서 구축한 태블릿 117개와 리뷰 7,552개를 대상으로 수행되었다. 그러나 실제 상품 구매에서 중요하게 고려되는 정보는 상품군에 따라 크게 달라질 수 있다. 예를 들어 태블릿에서는 성능·필기·디스플레이가 중요할 수 있지만, 선물에서는 구매 대상과 관계, 의류에서는 취향과 스타일, 고관여 가전에서는 설치·내구성·유지비가 중요한 의사결정 요인이 될 수 있다. 또한 실제 사용자는 연구자가 정의한 scenario보다 더 모호하게 요구를 표현하거나, 조건을 반복적으로 수정·철회하고, 대화 도중 새로운 기준을 제시할 수 있다. 향후에는 다양한 상품군과 실제 사용자 대화를 포함하는 환경에서 현재의 Dialogue State representation과 agent workflow가 얼마나 일반화되는지 검증할 필요가 있다.

마지막으로, 현재 시스템은 사용자의 요구에 따라 상품을 검색하고 추천하는 단계에 초점을 두며, 실제 commerce environment의 지속적인 변화와 구매 실행까지는 충분히 다루지 않는다. 실제 쇼핑에서는 가격, 재고, 배송 예정일, 할인 여부와 같은 정보가 지속적으로 변하며, 이러한 외부 상태는 사용자의 선호만큼이나 최종 구매 결정에 중요한 영향을 미친다.

향후에는 실시간 commerce API 또는 주기적으로 갱신되는 상품 정보를 활용하여 사용자 Dialogue State와 외부 상품 상태를 함께 추적하고, 상황 변화에 따라 상품을 능동적으로 재탐색·재순위화하는 구조로 확장할 수 있다. 더 나아가 사용자의 명시적인 승인 아래 장바구니 추가, 옵션 선택, 구매 확인과 같은 실제 transaction 단계까지 지원함으로써, 단순히 상품을 나열하는 추천 시스템을 넘어 구매 의사결정과 실행 과정을 지속적으로 지원하는 능동적 Shopping Agent로 발전시키는 것을 고려할 수 있다.

7. Conclusion

본 연구는 실제 쇼핑 과정에서 사용자의 요구와 우선순위가 대화에 따라 지속적으로 변화한다는 점에 주목하여, 이러한 변화를 **Dialogue State**로 누적·관리하고 상품 검색과 **ranking**에 반영하는 **multi-turn shopping agent**를 구성하였다. 제안한 시스템은 사용자 발화로부터 구매 상황과 제약 및 선호를 구조화하고, 이를 **persistent Dialogue State**에 반영한 뒤 상태의 구체성에 따라 추가 질문 또는 추천을 수행한다. 또한 실제 상품 **metadata**와 **review evidence**를 검색하여 현재까지 확인된 사용자 요구에 따라 후보 상품을 재순위화함으로써, 각 턴을 독립적인 검색 요청으로 처리하기보다 사용자의 의사결정 상태가 대화 과정에서 변화하는 연속적인 쇼핑 과정으로 모델링하였다.

20개의 **multi-turn** 구매 **scenario**, 총 81개 **turn**을 대상으로 한 평가에서 **persistent Dialogue State**를 사용하는 **Full** 조건은 **No-Memory** 조건보다 **Final State micro-F1**이 **0.258** 높게 나타나, 이전 턴에서 확인된 정보를 유지하는 것이 대화 종료 시점의 누적 사용자 요구를 보존하는 데 효과적임을 확인하였다. 반면 **State Diff micro-F1**은 **0.138** 낮게 나타나, 장기적인 상태 유지와 현재 턴에서 실제로 새롭게 발생한 변화의 식별이 서로 다른 문제임을 보여주었다. 이는 **multi-turn recommendation**에서 단순히 많은 대화 정보를 기억하는 것뿐 아니라, 과거 상태의 유지와 현재 상태의 변화를 구분하여 관리하는 것이 중요함을 시사한다.

또한 추론된 **Dialogue State**를 **Gold-State**로 대체한 **diagnostic analysis**에서 **Policy Accuracy**, **Recommendation Reach**, **Hard-filter Completion**이 모두 1.000으로 회복되었다. 이는 본 시스템에서 관찰된 주요 성능 손실이 **downstream recommendation logic** 자체보다는 사용자 요구를 해석하고 정확한 상태로 구성하는 과정과 밀접하게 연관되어 있음을 보여준다. 한편 **review-based score**를 제거했을 때 **Top-1** 추천의 **55.6%**, **Top-3** 상품 순서의 **87.3%**가 변화하여 **review evidence**가 실제 **ranking** 결정에 실질적인 신호로 사용되고 있음을 확인하였다.

종합하면, 본 연구는 대화형 쇼핑 에이전트의 핵심을 단순한 상품 검색이나 최종 상품 예측에 두기보다, 대화 과정에서 확인·수정되는 사용자 요구를 지속적인 의사결정 상태로 관리하고 그 변화를 실제 검색과 추천 과정에 연결하는 문제로 확장하였다. 실험 결과는 **persistent Dialogue State**의 필요성과 동시에 정교한 **State Update**의 필요성을 보여주었으며, **review evidence**가 상태 기반 상품 **ranking**에 실제로 기여할 수 있음을 확인하였다. 이를 통해 본 연구는 향후 사용자와 상품 환경의 변화를 함께 추적하고, 추천을 넘어 실제 구매 의사결정 과정까지 지속적으로 지원하는 **shopping agent**를 구축하기 위한 기반을 제시한다.

8. References

- [1] Jie Kang, Kyle Condiff, Shuo Chang, Joseph A. Konstan, Loren Terveen, and F. Maxwell Harper. 2017. Understanding How People Use Natural Language to Ask for Recommendations. In Proceedings of the Eleventh ACM Conference on Recommender Systems (RecSys '17). Association for Computing Machinery, New York, NY, USA, 229–237. <https://doi.org/10.1145/3109859.3109873>
- [2] Dietmar Jannach, Ahtsham Manzoor, Wanling Cai, and Li Chen. 2021. A Survey on Conversational Recommender Systems. *ACM Computing Surveys* 54, 5 (2021), Article 105, 1–36. <https://doi.org/10.1145/3453154>
- [3] Junze Chen, Xinjie Yang, Cheng Yang, Junfei Bao, Zeyuan Guo, Yawen Li, and Chuan Shi. 2025. CORONA: A Coarse-to-Fine Framework for Graph-based Recommendation with Large Language Models. In Proceedings of the 48th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '25). Association for Computing Machinery, New York, NY, USA, 2048–2058. <https://doi.org/10.1145/3726302.3729937>
- [4] Jiaxin Bai, Zhaobo Wang, Junfei Cheng, Dan Yu, Zerui Huang, Weiqi Wang, Xin Liu, Chen Luo, Yanming Zhu, Bo Li, and Yangqiu Song. 2026. Intention Knowledge Graph Construction for User Intention Relation Modeling. In Proceedings of the 19th Conference of the European Chapter of the Association for Computational Linguistics (Volume 1: Long Papers). Association for Computational Linguistics, Rabat, Morocco, 466–484. <https://doi.org/10.18653/v1/2026.eacl-long.21>
- [5] Preetam Prabhu Srikanth Damu, Omar Alonso, and Barbara Poblete. 2025. A Shopping Agent for Addressing Subjective Product Needs. In Proceedings of the Eighteenth ACM International Conference on Web Search and Data Mining (WSDM '25). Association for Computing Machinery, 1032–1035. <https://doi.org/10.1145/3701551.3704124>
- [6] Jason D. Williams, Antoine Raux, and Matthew Henderson. 2016. The Dialog State Tracking Challenge Series: A Review. *Dialogue & Discourse* 7, 3 (2016), 4–33. <https://doi.org/10.5087/dad.2016.301>
- [7] Sara Kemper, Justin Cui, Kai Dicarlantonio, Kathy Lin, Danjie Tang, Anton Korikov, and Scott Sanner. 2024. Retrieval-Augmented Conversational Recommendation with Prompt-based Semi-Structured Natural Language State Tracking. In Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '24). Association for Computing Machinery, New York, NY, USA, 2786–2790. <https://doi.org/10.1145/3626772.3657670>
- [8] Yupeng Hou, Jiacheng Li, Zhankui He, An Yan, Xiusi Chen, and Julian McAuley. 2024. Bridging Language and Items for Retrieval and Recommendation. *arXiv preprint arXiv:2403.03952* (2024)
- [9] Mohammad Mahdi Abdollah Pour, Parsa Farinneya, Armin Toroghi, Anton Korikov, Ali Pesaranghader, Touqir Sajed, Manasa Bharadwaj, Borislav Mavrin, and Scott Sanner. 2023. Self-Supervised Contrastive BERT Fine-Tuning for Fusion-Based Reviewed-Item Retrieval. In *Advances in Information Retrieval: 45th European Conference on Information Retrieval (ECIR 2023)*, Proceedings, Part I. Springer, 3–17. https://doi.org/10.1007/978-3-031-28244-7_1
- [10] Nils Reimers and Iryna Gurevych. 2019. Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. In Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP). Association for Computational Linguistics, 3982–3992. <https://doi.org/10.18653/v1/D19-1410>